Введение в искусственный интеллект. Современное компьютерное зрение

Тема семинара: Несверточные слои

Бабин Д.Н., Иванов И.Е.

кафедра Математической Теории Интеллектуальных Систем

27 февраля 2024 г.

План семинара

1. Сведение к свертке
2. О сигмоиде
3. Сверточные механизмы внимания

Пакетная нормализация при тесте

- Предположим, что мы используем пакет размера $T = 1$ (здесь и далее опустим этот индекс)

Пакетная нормализация при тесте

- Предположим, что мы используем пакет размера $T = 1$ (здесь и далее опустим этот индекс)
- Y_{ij}^k — трехмерный тензор значений для некоторого слоя, где

Пакетная нормализация при тесте

- Предположим, что мы используем пакет размера $T = 1$ (здесь и далее опустим этот индекс)
- Y_{ij}^k — трехмерный тензор значений для некоторого слоя, где
  - $1 \le i \le H, 1 \le j \le W$ — пространственные координаты (ширина и высота),
  - $k = 1 \dots K$ — номер карты признаков.

Пакетная нормализация при тесте

- Предположим, что мы используем пакет размера $T = 1$ (здесь и далее опустим этот индекс)
- Y_{ij}^k — трехмерный тензор значений для некоторого слоя, где
  - $1 \leq i \leq H, 1 \leq j \leq W$ — пространственные координаты (ширина и высота),
  - $k = 1 \dots K$ — номер карты признаков.
- Выход нормализованного слоя: $Z_{ij}^k = \gamma^k \frac{Y_{ij}^k - \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$

Пакетная нормализация как линейная операция от входа

- $Z_{ij}^k = \gamma^k \frac{Y_{ij}^k - \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$

Пакетная нормализация как линейная операция от входа

- $Z_{ij}^k = \gamma^k \frac{Y_{ij}^k - \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$
- Перепишем формулу в другом виде:

Пакетная нормализация как линейная операция от входа

- $Z_{ij}^k = \gamma^k \frac{Y_{ij}^k - \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$
- Перепишем формулу в другом виде:

$$Z_{ij}^k = Y_{ij}^k \frac{\gamma^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} - \frac{\gamma^k \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$$

Пакетная нормализация как линейная операция от входа

- $Z_{ij}^k = \gamma^k \frac{Y_{ij}^k - \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$
- Перепишем формулу в другом виде:

$$Z_{ij}^k = Y_{ij}^k \frac{\gamma^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} - \frac{\gamma^k \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$$

- Т.о., получаем $Z_{ij}^k = G^k Y_{ij}^k + g^k$, где

Пакетная нормализация как линейная операция от входа

- $Z_{ij}^k = \gamma^k \frac{Y_{ij}^k - \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$
- Перепишем формулу в другом виде:

$$Z_{ij}^k = Y_{ij}^k \frac{\gamma^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} - \frac{\gamma^k \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$$

- Т.о., получаем $Z_{ij}^k = G^k Y_{ij}^k + g^k$, где
  - Мультипликативный член $G^k = \frac{\gamma^k}{\sqrt{\sigma_{avg}^{\mathbf{2}k} + \epsilon}}$,

Пакетная нормализация как линейная операция от входа

- $Z_{ij}^k = \gamma^k \frac{Y_{ij}^k - \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$
- Перепишем формулу в другом виде:

$$Z_{ij}^k = Y_{ij}^k \frac{\gamma^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} - \frac{\gamma^k \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}} + \beta^k$$

- Т.о., получаем $Z_{ij}^k = G^k Y_{ij}^k + g^k$, где
  - Мультипликативный член $G^k = \frac{\gamma^k}{\sqrt{\sigma_{avg}^{\mathbf{2}k} + \epsilon}}$,
  - Аддитивный член $g^k = \beta^k - \frac{\gamma^k \mu_{avg}^k}{\sqrt{\sigma_{avg}^{\mathbf{2}k} + \epsilon}}$.

Пакетная нормализация как свертка

- $Z_{ij}^k = G^k Y_{ij}^k + g^k$

Пакетная нормализация как свертка

- $Z_{ij}^k = G^k Y_{ij}^k + g^k$
- Значит, пакетная нормализация — это поканальная (depthwise, *см.* предыдущую лекцию) свертка с ядром размера 1×1!

Пакетная нормализация как свертка

- $Z_{ij}^k = G^k Y_{ij}^k + g^k$
- Значит, пакетная нормализация — это поканальная (depthwise, *см.* предыдущую лекцию) свертка с ядром размера 1×1!
- А композиция сверток — тоже свертка (*Упражнение*: доказать)

Объединение свертки и пакетной нормализации (1)

- Обычно: сначала свертка, потом пакетная нормализация

Объединение свертки и пакетной нормализации (1)

- Обычно: сначала свертка, потом пакетная нормализация
- По слоям:

Объединение свертки и пакетной нормализации (1)

- Обычно: сначала свертка, потом пакетная нормализация
- По слоям:

$$X_{ij}^m \xrightarrow{F_{uv}^{mk}, b^k} Y_{ij}^k \xrightarrow{G^k, g^k} Z_{ij}^k$$

Объединение свертки и пакетной нормализации (1)

- Обычно: сначала свертка, потом пакетная нормализация
- По слоям:

$$X_{ij}^{m} \xrightarrow{F_{uv}^{mk}, b^k} Y_{ij}^{k} \xrightarrow{G^k, g^k} Z_{ij}^{k}$$

- Выписываем еще раз формулы для свертки:

Объединение свертки и пакетной нормализации (1)

- Обычно: сначала свертка, потом пакетная нормализация
- По слоям:

$$X_{ij}^{m} \xrightarrow{F_{uv}^{mk}, b^k} Y_{ij}^{k} \xrightarrow{G^k, g^k} Z_{ij}^{k}$$

- Выписываем еще раз формулы для свертки:

$$Y_{ij}^{k} = \sum_{m=1}^{M} \sum_{u,v=1}^{p,q} X_{i+u-1,j+v-1}^{m} \cdot F_{uv}^{mk} + b^k, \quad \forall k = 1 \ldots K$$

и для пакетной нормализации:

Объединение свертки и пакетной нормализации (1)

- Обычно: сначала свертка, потом пакетная нормализация
- По слоям:

$$X_{ij}^{m} \xrightarrow{F_{uv}^{mk}, b^k} Y_{ij}^{k} \xrightarrow{G^k, g^k} Z_{ij}^{k}$$

- Выписываем еще раз формулы для свертки:

$$Y_{ij}^{k} = \sum_{m=1}^{M} \sum_{u,v=1}^{p,q} X_{i+u-1,j+v-1}^{m} \cdot F_{uv}^{mk} + b^k, \quad \forall k = 1 \dots K$$

и для пакетной нормализации:

$$Z_{ij}^{k} = G^k Y_{ij}^{k} + g^k$$

.

Объединение свертки и пакетной нормализации (2)

- Объединяя, получим:

- Объединяя, получим:

$$Z_{ij}^{k} = \sum_{m=1}^{M} \sum_{u,v=1}^{p,q} X_{i+u-1,j+v-1}^{m} \cdot F_{uv}^{mk} \cdot G^{k} + b^{k} + g^{k}, \quad \forall k = 1 \dots K$$

- Т.о., мы получили свертку с параметрами O_{uv}^{mk}, o^{k}, где (подтягиваем параметры пакетной нормализации):

Объединение свертки и пакетной нормализации (2)

- Объединяя, получим:

$$Z_{ij}^k = \sum_{m=1}^{M} \sum_{u,v=1}^{p,q} X_{i+u-1,j+v-1}^m \cdot F_{uv}^{mk} \cdot G^k + b^k + g^k, \quad \forall k = 1 \dots K$$

- Т.о., мы получили свертку с параметрами O_{uv}^{mk}, o^k, где (подтягиваем параметры пакетной нормализации):
  - Ядро $O_{uv}^{mk} = F_{uv}^{mk} \cdot \frac{\gamma^k}{\sqrt{\sigma_{avg}^{\mathbf{2}k} + \epsilon}}$,

Объединение свертки и пакетной нормализации (2)

- Объединяя, получим:

$$Z_{ij}^k = \sum_{m=1}^{M} \sum_{u,v=1}^{p,q} X_{i+u-1,j+v-1}^m \cdot F_{uv}^{mk} \cdot G^k + b^k + g^k, \quad \forall k = 1 \ldots K$$

- Т.о., мы получили свертку с параметрами O_{uv}^{mk}, o^k, где (подтягиваем параметры пакетной нормализации):
    - Ядро $O_{uv}^{mk} = F_{uv}^{mk} \cdot \frac{\gamma^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}}$,
    - Аддитивный член $o^k = b^k + \beta^k - \frac{\gamma^k \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}}$.

Объединение свертки и пакетной нормализации (2)

- Объединяя, получим:

$$Z_{ij}^k = \sum_{m=1}^{M} \sum_{u,v=1}^{p,q} X_{i+u-1,j+v-1}^m \cdot F_{uv}^{mk} \cdot G^k + b^k + g^k, \quad \forall k = 1 \dots K$$

- Т.о., мы получили свертку с параметрами O_{uv}^{mk}, o^k, где (подтягиваем параметры пакетной нормализации):
  - Ядро $O_{uv}^{mk} = F_{uv}^{mk} \cdot \frac{\gamma^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}}$,
  - Аддитивный член $o^k = b^k + \beta^k - \frac{\gamma^k \mu_{avg}^k}{\sqrt{\sigma_{avg}^{2k} + \epsilon}}$.
- Из $X_{ij}^m \xrightarrow{F_{uv}^{mk}, b^k} Y_{ij}^k \xrightarrow{G^k, g^k} Z_{ij}^k$ получили $X_{ij}^m \xrightarrow{O_{uv}^{mk}, o^k} Z_{ij}^k$.

Субдискретизация как свертка

- **Вопрос**: Можно ли maxpooling представить как свертку?

Субдискретизация как свертка

- **Вопрос**: Можно ли maxpooling представить как свертку?
- **Ответ**: Нет, так как операция взятия максимума — нелинейная (в то время как **свертка всегда линейна**)

Субдискретизация как свертка

- **Вопрос**: Можно ли maxpooling представить как свертку?
- **Ответ**: Нет, так как операция взятия максимума — нелинейная (в то время как **свертка всегда линейна**)
- **Вопрос**: Можно ли average pooling представить как свертку?

Субдискретизация как свертка

- **Вопрос**: Можно ли maxpooling представить как свертку?
- **Ответ**: Нет, так как операция взятия максимума — нелинейная (в то время как **свертка всегда линейна**)
- **Вопрос**: Можно ли average pooling представить как свертку?
- **Ответ**: Да, и рассмотрим на примере global average pooling (GAP):

Субдискретизация как свертка

- **Вопрос**: Можно ли maxpooling представить как свертку?
- **Ответ**: Нет, так как операция взятия максимума — нелинейная (в то время как **свертка всегда линейна**)
- **Вопрос**: Можно ли average pooling представить как свертку?
- **Ответ**: Да, и рассмотрим на примере global average pooling (GAP):
  - Пусть двухмерный (не обращаем внимание на карты) вход $X_{ij}, 1 \leq i \leq H, 1 \leq j \leq W$,

Субдискретизация как свертка

- **Вопрос**: Можно ли maxpooling представить как свертку?
- **Ответ**: Нет, так как операция взятия максимума — нелинейная (в то время как **свертка всегда линейна**)
- **Вопрос**: Можно ли average pooling представить как свертку?
- **Ответ**: Да, и рассмотрим на примере global average pooling (GAP):
  - Пусть двухмерный (не обращаем внимание на карты) вход $X_{ij}, 1 \leq i \leq H, 1 \leq j \leq W$,
  - $GAP2D(X) = \frac{1}{HW} \sum_{i,j=1}^{H,W} X_{ij}$,

Субдискретизация как свертка

- **Вопрос**: Можно ли maxpooling представить как свертку?
- **Ответ**: Нет, так как операция взятия максимума — нелинейная (в то время как **свертка всегда линейна**)
- **Вопрос**: Можно ли average pooling представить как свертку?
- **Ответ**: Да, и рассмотрим на примере global average pooling (GAP):
  - Пусть двухмерный (не обращаем внимание на карты) вход $X_{ij}, 1 \leq i \leq H, 1 \leq j \leq W$,
  - $GAP2D(X) = \frac{1}{HW} \sum_{i,j=1}^{H,W} X_{ij}$,
  - Тогда свертка, соответствующая $GAP2D(X)$ — это свертка с ядром $F_{GAP} = \frac{1}{HW} \mathbb{1}_{i,j=1}^{H,W}$ без аддитивного члена, с размером, как у входа $H \times W$, применяемая без добивки (паддинга) и в режиме “VALID”

О сигмоиде

- Вспомним три основных вида активации:

О сигмоиде

- Вспомним три основных вида активации:
  1. Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$,

О сигмоиде

- Вспомним три основных вида активации:
  1. Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$,
  2. Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$,

О сигмоиде

- Вспомним три основных вида активации:
  1. Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$,
  2. Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$,
  3. Rectified Linear Unit $ReLU(x) = \max(0, x)$.

О сигмоиде

- Вспомним три основных вида активации:
  1. Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$,
  2. Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$,
  3. Rectified Linear Unit $ReLU(x) = \max(0, x)$.
- Изначально все использовали $\sigma(x)$. Тем не менее, сейчас он почти не встречается. Почему?

О сигмоиде

- Вспомним три основных вида активации:
  1. Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$,
  2. Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$,
  3. Rectified Linear Unit $ReLU(x) = \max(0, x)$.
- Изначально все использовали $\sigma(x)$. Тем не менее, сейчас он почти не встречается. Почему?
- **Проблема**: выход $\sigma(x)$ — не центрирован в нуле.

О сигмоиде

- Вспомним три основных вида активации:
  1. Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$,
  2. Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$,
  3. Rectified Linear Unit $ReLU(x) = \max(0, x)$.
- Изначально все использовали $\sigma(x)$. Тем не менее, сейчас он почти не встречается. Почему?
- **Проблема**: выход $\sigma(x)$ — не центрирован в нуле.
- **Решение**: использовать $\tanh(x)$.

О сигмоиде

- Вспомним три основных вида активации:
  1. Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$,
  2. Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$,
  3. Rectified Linear Unit $ReLU(x) = \max(0, x)$.
- Изначально все использовали $\sigma(x)$. Тем не менее, сейчас он почти не встречается. Почему?
- **Проблема**: выход $\sigma(x)$ — не центрирован в нуле.
- **Решение**: использовать $\tanh(x)$.
- Однако это не избавляет от главной проблемы — **исчезающих градиентов**:
  1. Производная $\sigma'(x) = \sigma(x)(1 - \sigma(x))$,

О сигмоиде

- Вспомним три основных вида активации:
  1. Сигмоида $\sigma(x) = \frac{1}{1+\exp(-x)}$,
  2. Гиперболический тангенс $\tanh(x) = 2\sigma(2x) - 1$,
  3. Rectified Linear Unit $ReLU(x) = \max(0, x)$.
- Изначально все использовали $\sigma(x)$. Тем не менее, сейчас он почти не встречается. Почему?
- **Проблема**: выход $\sigma(x)$ — не центрирован в нуле.
- **Решение**: использовать $\tanh(x)$.
- Однако это не избавляет от главной проблемы — **исчезающих градиентов**:
  1. Производная $\sigma'(x) = \sigma(x)(1 - \sigma(x))$,
  2. Для любых больших по модулю x $\sigma(x)$ стремится к 1 или 0, и соответственно его производная — всегда к нулю.

О ReLU[1]

- $ReLU(x) = \max(0, x)$ дает нулевую производную только при отрицательных x,

[1] https://stats.stackexchange.com/a/422579

О ReLU[1]

- $ReLU(x) = \max(0, x)$ дает нулевую производную только при отрицательных x,
- $ReLU(x)$ при $x > 0$ дает константную производную (равную 1),

[1] https://stats.stackexchange.com/a/422579

О ReLU[1]

- $ReLU(x) = \max(0, x)$ дает нулевую производную только при отрицательных x,
- $ReLU(x)$ при $x > 0$ дает константную производную (равную 1),
- $ReLU(x)$ потрясающе эффективен в реализации на конечном устройстве.

[1] https://stats.stackexchange.com/a/422579

О ReLU[1]

- $ReLU(x) = \max(0, x)$ дает нулевую производную только при отрицательных x,
- $ReLU(x)$ при $x > 0$ дает константную производную (равную 1),
- $ReLU(x)$ потрясающе эффективен в реализации на конечном устройстве.
- Иллюстрация:

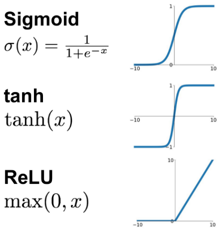

[1] https://stats.stackexchange.com/a/422579

О ReLU[1]

- $ReLU(x) = \max(0, x)$ дает нулевую производную только при отрицательных x,
- $ReLU(x)$ при $x > 0$ дает константную производную (равную 1),
- $ReLU(x)$ потрясающе эффективен в реализации на конечном устройстве.
- Иллюстрация:

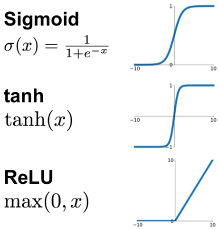

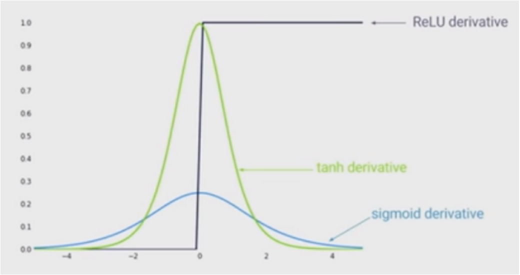

[1] https://stats.stackexchange.com/a/422579

Сверточные механизмы внимания: поканальный (1)

- Вводится механизм внимания на конкретные карты

[2] Hu, Jie, Li Shen, and Gang Sun. "Squeeze-and-excitation networks." 2017

Сверточные механизмы внимания: поканальный (1)

- Вводится механизм внимания на конкретные карты
- *Внимание* — это обычно мультипликативный коэффициент $a \in [0, 1]$ (вес)

[2] Hu, Jie, Li Shen, and Gang Sun. "Squeeze-and-excitation networks." 2017

Сверточные механизмы внимания: поканальный (1)

- Вводится механизм внимания на конкретные карты
- *Внимание* — это обычно мультипликативный коэффициент $a \in [0, 1]$ (вес)
- Важность карты агрегируется через MaxPool / AvgPool по пространственным размерностям: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : C \times 1 \times 1$

[2] Hu, Jie, Li Shen, and Gang Sun. "Squeeze-and-excitation networks." 2017

Сверточные механизмы внимания: поканальный (1)

- Вводится механизм внимания на конкретные карты
- *Внимание* — это обычно мультипликативный коэффициент $a \in [0, 1]$ (вес)
- Важность карты агрегируется через MaxPool / AvgPool по пространственным размерностям: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : C \times 1 \times 1$
- После чего применяется двухслойный перцептрон, при этом для уменьшения количества параметров применяется сжимающе-разжимающее отображение с параметром r: $Y_1 = W_1 RELU(W_0 F_{agg}), W_0 : C/r \times C, W_1 : C \times C/r$

[2] Hu, Jie, Li Shen, and Gang Sun. "Squeeze-and-excitation networks." 2017

Сверточные механизмы внимания: поканальный (1)

- Вводится механизм внимания на конкретные карты
- *Внимание* — это обычно мультипликативный коэффициент $a \in [0, 1]$ (вес)
- Важность карты агрегируется через MaxPool / AvgPool по пространственным размерностям: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : C \times 1 \times 1$
- После чего применяется двухслойный перцептрон, при этом для уменьшения количества параметров применяется сжимающе-разжимающее отображение с параметром r: $Y_1 = W_1 RELU(W_0 F_{agg}), W_0 : C/r \times C, W_1 : C \times C/r$
- Коэффициент внимания вычисляется через сигмоид: $Y = \sigma(Y_1)$

[2] Hu, Jie, Li Shen, and Gang Sun. "Squeeze-and-excitation networks." 2017

Сверточные механизмы внимания: поканальный (1)

- Вводится механизм внимания на конкретные карты
- *Внимание* — это обычно мультипликативный коэффициент $a \in [0, 1]$ (вес)
- Важность карты агрегируется через MaxPool / AvgPool по пространственным размерностям: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : C \times 1 \times 1$
- После чего применяется двухслойный перцептрон, при этом для уменьшения количества параметров применяется сжимающе-разжимающее отображение с параметром r: $Y_1 = W_1 RELU(W_0 F_{agg}), W_0 : C/r \times C, W_1 : C \times C/r$
- Коэффициент внимания вычисляется через сигмоид: $Y = \sigma(Y_1)$
- В конце исходный тензор $X : C \times H \times W$ в каждой пространственной размерности поэлементно перемножается на тензор внимания $Y : C \times 1 \times 1$

[2] Hu, Jie, Li Shen, and Gang Sun. "Squeeze-and-excitation networks." 2017

Сверточные механизмы внимания: поканальный (1)

- Вводится механизм внимания на конкретные карты
- *Внимание* — это обычно мультипликативный коэффициент $a \in [0, 1]$ (вес)
- Важность карты агрегируется через MaxPool / AvgPool по пространственным размерностям: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : C \times 1 \times 1$
- После чего применяется двухслойный перцептрон, при этом для уменьшения количества параметров применяется сжимающе-разжимающее отображение с параметром r: $Y_1 = W_1 RELU(W_0 F_{agg}), W_0 : C/r \times C, W_1 : C \times C/r$
- Коэффициент внимания вычисляется через сигмоид: $Y = \sigma(Y_1)$
- В конце исходный тензор $X : C \times H \times W$ в каждой пространственной размерности поэлементно перемножается на тензор внимания $Y : C \times 1 \times 1$
- Популярность этод вид внимания приобрел под названием “Squeeze-and-Excitation”[2]

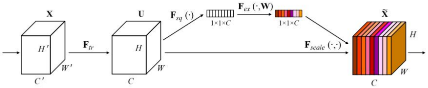

[2] Hu, Jie, Li Shen, and Gang Sun. “Squeeze-and-excitation networks.” 2017

Сверточные механизмы внимания: поканальный (2)

- На иллюстрации ниже сделана комбинация MaxPool и AvgPool через сумму
- При этом двухслойный перцептрон один и тот же

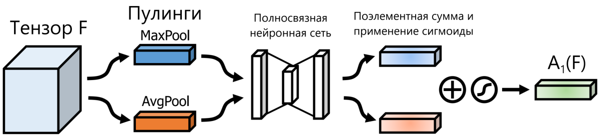

Сверточные механизмы внимания: пространственный (1)

- Вводится также механизм внимания на конкретные пространственные позиции (но уже без учета карт!)

[3] Wang, Fei, et al. "Residual attention network for image classification." 2017

Сверточные механизмы внимания: пространственный (1)

- Вводится также механизм внимания на конкретные пространственные позиции (но уже без учета карт!)
- Важность позиции агрегируется так же — через MaxPool / AvgPool, но уже не по пространственным размерностям, а поканально:
  $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : 1 \times H \times W$

[3] Wang, Fei, et al. "Residual attention network for image classification." 2017

Сверточные механизмы внимания: пространственный (1)

- Вводится также механизм внимания на конкретные пространственные позиции (но уже без учета карт!)
- Важность позиции агрегируется так же — через MaxPool / AvgPool, но уже не по пространственным размерностям, а поканально: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : 1 \times H \times W$
- После чего применяется обычная двухмерная свертка W размерности $k \times k$ для сглаживания: $Y_1 = W * F_{agg}$

[3] Wang, Fei, et al. "Residual attention network for image classification." 2017

Сверточные механизмы внимания: пространственный (1)

- Вводится также механизм внимания на конкретные пространственные позиции (но уже без учета карт!)
- Важность позиции агрегируется так же — через MaxPool / AvgPool, но уже не по пространственным размерностям, а поканально: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : 1 \times H \times W$
- После чего применяется обычная двухмерная свертка W размерности $k \times k$ для сглаживания: $Y_1 = W * F_{agg}$
- Коэффициент внимания вычисляется через сигмоид: $Y = \sigma(Y_1)$

[3] Wang, Fei, et al. "Residual attention network for image classification." 2017

Сверточные механизмы внимания: пространственный (1)

- Вводится также механизм внимания на конкретные пространственные позиции (но уже без учета карт!)
- Важность позиции агрегируется так же — через MaxPool / AvgPool, но уже не по пространственным размерностям, а поканально: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : 1 \times H \times W$
- После чего применяется обычная двухмерная свертка W размерности $k \times k$ для сглаживания: $Y_1 = W * F_{agg}$
- Коэффициент внимания вычисляется через сигмоид: $Y = \sigma(Y_1)$
- В конце исходный тензор $X : C \times H \times W$ в каждой карте поэлементно перемножается на тензор внимания $Y : 1 \times H \times W$

[3] Wang, Fei, et al. "Residual attention network for image classification." 2017

Сверточные механизмы внимания: пространственный (1)

- Вводится также механизм внимания на конкретные пространственные позиции (но уже без учета карт!)
- Важность позиции агрегируется так же — через MaxPool / AvgPool, но уже не по пространственным размерностям, а поканально: $F_{agg} = AGG(X), X : C \times H \times W, F_{agg} : 1 \times H \times W$
- После чего применяется обычная двухмерная свертка W размерности $k \times k$ для сглаживания: $Y_1 = W * F_{agg}$
- Коэффициент внимания вычисляется через сигмоид: $Y = \sigma(Y_1)$
- В конце исходный тензор $X : C \times H \times W$ в каждой карте поэлементно перемножается на тензор внимания $Y : 1 \times H \times W$
- Одно из первых применений этод вид внимания прошло под названием "Residual Attention"[3]

[3] Wang, Fei, et al. "Residual attention network for image classification." 2017

Сверточные механизмы внимания: пространственный (2)

- На иллюстрации ниже сделана комбинация MaxPool и AvgPool через конкатенацию карт
- Итоговая свертка имеет размерность уже не $1 \times k \times k$, а $2 \times k \times k$

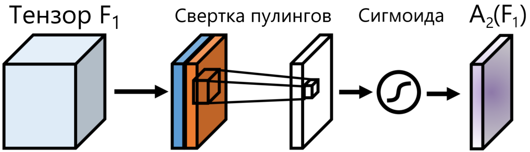

Сверточные механизмы внимания: комбинация

- Оказывается, можно комбинировать поканальный и пространственный механизмы внимания

[4] Woo, Sanghyun, et al. "Cbam: Convolutional block attention module." 2018

Сверточные механизмы внимания: комбинация

- Оказывается, можно комбинировать поканальный и пространственный механизмы внимания
- При этом наилучшие результаты давал подход. где сначала применяется поканальный, а затем – пространственный механизмы внимания

[4] Woo, Sanghyun, et al. "Cbam: Convolutional block attention module." 2018

Сверточные механизмы внимания: комбинация

- Оказывается, можно комбинировать поканальный и пространственный механизмы внимания
- При этом наилучшие результаты давал подход. где сначала применяется поканальный, а затем – пространственный механизмы внимания
- Наибольшую известность такой подход получил с названием "Convolutional Block Attention Module"[4]

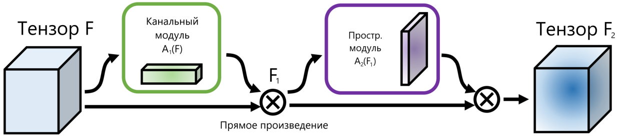

[4] Woo, Sanghyun, et al. "Cbam: Convolutional block attention module." 2018

Внимание на себя (self-attention)

- Тем не менее, на данный момент наибольшей популярностью ползуется механизм внимания, предназначенный для обработки естественных языков, под названием self-attention[5]

[5] Vaswani, Ashish, et al. "Attention is all you need." 2017

Внимание на себя (self-attention)

- Тем не менее, на данный момент наибольшей популярностью ползуется механизм внимания, предназначенный для обработки естественных языков, под названием self-attention[5]
- To be coming soon...

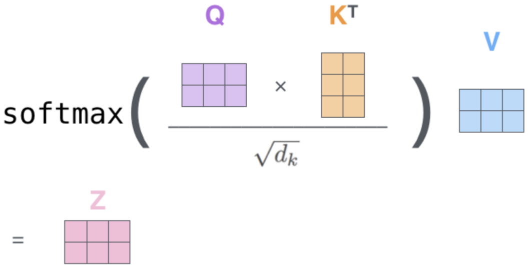

$$\mathrm{softmax}\left(\frac{Q \times K^T}{\sqrt{d_k}}\right) V = Z$$

The self-attention calculation in matrix form

[5] Vaswani, Ashish, et al. "Attention is all you need." 2017

Время для вопросов

Спасибо за внимание!